

李智维

AI 全栈工程师

中国广州黄埔

☎ (+86) 132-6163-0925 | ✉ lzwjava@gmail.com | 🏠 lzwjava.com | 📷 lzwjava | 🌐 lzwjava



“真理”

个人概述

- 男，1995 年生，中国公民，现居广州。2011 年广东 NOIP 省赛前 300 名，在线解决约 1000 道算法题。
- 在北京林业大学就读一年后退学。通过自学考试攻读专科学历，已完成十三门课程。
- 目前正在寻求新的工作机会。曾就职于 TEKsystems（外派汇丰银行）、LeanCloud、北京平方根、博彦科技（外派星展银行）和法本信息（外派汇丰银行）。
- 累计 11 年从业经验，包括 8 年企业任职和 3 年自由职业。专注于 2 年移动（Android, iOS）工程、8 年全栈工程（7 年后端，1 年前端）和 1 年机器学习/大数据。
- 熟练掌握 HTML、CSS、浏览器 API、JavaScript、Vue.js、React、Angular 以及 iOS/Android 开发。熟悉 Java、Spring、Spring Boot、MySQL、Redis、API 设计、网络协议、容器化和分布式系统。熟悉阿里云、AWS 和 Azure 上的日志、数据库和微服务模块部署。
- 母语中文，英语流利（雅思 6.5 分）。阅读超过 320 本书，涵盖教科书、个人成长、商业、科技和历史。过去一年阅读了约 8000 条详尽的 AI 长回答。
- 作为主要开发者，开发了 10 个 GitHub 开源项目，每个项目有超过 500 次提交，详见<https://github.com/lzwjava>。详细的软件作品集请访问<https://lzwjava.com/portfolio-en>。
- 乐于分享知识，博客有约 400 篇原创文章，每月吸引约 7.5 万页面浏览量，在企业环境中也大量撰写文档。
- 自学研究者，发表了一篇关于逆转近视和自然视力恢复的学术风格论文，灵感来源于 Yin Wang 和 Todd Becker 的作品，并经过三年实验验证。
- AI 爱好者——在 H200、AMD MI300X 和 RTX 4070 GPU 上训练了 13 个小型 LLM（nanoGPT、GPT-2 124M/760M/1.5B），从零构建了基于 SEC 文件的 SEC-EDGAR-GPT，并使用 OpenRouter 和 Claude Code 构建个人 AI 项目（过去一年使用约 30 亿 token）。

工作经历

- 作为 TEKsystems 外包至汇丰银行的 AI 工程师，利用 Copilot 及其 API 加速汇丰企业技术部财务转型平台一个模块的后端开发。该模块涵盖财务账本平台中的财务调整，管理调整和财务日记账的账目级控制。
- 我在汇丰的正式头衔是 Specialist Engineer，在 TEKsystems 的头衔是 Full Stack Engineer。然而，鉴于我的工作性质以及我大量使用 AI 工具和 Copilot 技术来增强开发工作流，“AI 全栈工程师”是对我角色最准确的描述。
- 维护了财务数据处理（包括导入、验证和导出）的功能，同时增强了新财务表头的提交和审批工作流程。积累了会计、账本和银行系统方面的经验。
- 参与了从本地开发到 UAT 测试和生产发布的完整开发生命周期。帮助退役运行在 WebSphere Application Server 上的遗留应用。使用 Ansible 和 Jenkins 自动化发布，协助将 Angular 升级到主版本，乐于解决各类任务——尤其是为团队解决瓶颈问题。
- 负责模块的集成和 API 测试，使用 Copilot API 自动生成了约 70 个测试用例，涵盖 Java 中的 Spring Filters、Python unittest、JSON 截断、提示工程和区域端点。
- 将自己打造成为自主的人形 AI 代理，通过脚本、日志、文档和分享，尽可能地实现自动化。通过 LLM 输出的缓存和验证，为 20 个定制代理提供专用提示和上下文，并在整个技术栈中使用了 400 个可重用的 Copilot 编写的脚本和 1100 份 Copilot 编写的指南，在大型银行里的工程体验开始变得良好。并且在内部以 premium requests 指标衡量的 Copilot 使用量中排名前 6%。加入汇丰内部 AI 社区，并凭借高关注度项目 AIPlayer 获得贡献奖。
- 技术栈包括 Java、Spring、IBM Db2、Maven、Nexus、Angular、Python、HashiCorp Vault 等技术，以及 Windows、Control-M、IBM WebSphere Liberty Profile 和 Copilot 等工具。
- 与首席工程师合作开发涉及大型 Excel 文件处理和合并/联合工具的项目，用于比较多个银行系统之间的差距和差异，使用 Python、DuckDB、React 和 Copilot。
- 业余时间持续探索 AI：在 H200、RTX 4070 和 AMD MI300X GPU 上训练小模型（nanoGPT、GPT-2 760M、SEC-EDGAR-GPT 124M）并在个人知识库文本（约 500 万 token）上微调模型；使用 Qwen-27B 进行推理；通过 OpenRouter 和 Claude Code 构建个人项目（过去一年消耗约 30 亿 token）；初步学习了 PyTorch、ROCm、FlashAttention、Codex、llama.cpp、Transformers 和推理技术的基础知识。参加 NVIDIA 加速计算开发者技术交流会，向行业专家学习技术。

个人执业

中国广州

独立 AI 工程师

2023 年 8 月 - 2025 年 1 月

- 分析并重构约 30 个机器学习项目的核心组件，项目来源包括 PyTorch/TensorFlow 教程、Coursera 课程及开源仓库。获得两项 Coursera 认证：机器学习专项课程和深度学习专项课程。
- 备考专升本课程，主攻高等数学、计算机组成原理和线性代数。通过日本音乐和 TikTok 视频沉浸式学习日语。
- 作为全栈开发者参与 AI 故事机器人开发，基于 Claude API 实现个性化叙事功能。使用 Python/Flask/React/Nginx 构建提示配置系统和管理界面，部署于 AWS 云平台，采用 Prometheus 监控和 ELK 日志管理，ChatGPT-4 辅助编码。
- 维护原创技术博客（<https://lzwjava.com>，431 篇），运用大语言模型实现 9 语种翻译、文本转语音及 PDF/EPUB 格式支持。集成 GitHub 工作流，使用 LaTeX 排版学术论文和简历。技术栈涵盖 Python/Jekyll/Deepseek/Mistral。
- 实验研究 llama.cpp/嵌入模型/重排序/RAG 架构及 MMLU 基准测试，集成 Jina AI/Tavily AI Search/ElevenLabs 等搜索引擎 API。

深圳法本信息技术有限公司

中国广州

后端工程师（外派至汇丰银行）

2022 年 11 月 - 2023 年 7 月

- 法本是中国领先的软件技术服务商。汇丰银行是全球最大的银行及金融服务机构之一。PayMe 是汇丰面向香港居民开启的移动支付服务。
- 外派至汇丰银行参与 PayMe 项目。参与自动充值功能后端开发：监控 Azure EventHub 支付事件，当用户余额不足时自动从绑定的卡片扣款。采用面向对象编程优雅处理业务逻辑，通过 AOP 实现审计日志。
- 完成公司 AWS 培训后主导 API 云迁移：实现基于请求头的路由策略，确保数据库安全配置，参与微服务云原生部署。
- 技术栈包括 Java/Spring/Kafka，云服务采用 Azure/Azure DevOps/AWS。

北京博彦科技股份有限公司

中国广州

后端工程师（外派至星展银行）

2021 年 12 月 - 2022 年 11 月

- 博彦科技是领先的业务 IT 和咨询公司。星展银行（DBS）是东南亚资产规模最大的银行，也是亚洲最大的银行之一。外派至星展银行，参与 DBS Client Connect 和 DBS DigiBank CN 项目开发。
- 在股票交易系统（DBS Client Connect）中实现股票展示、客户信息、交易前检查及订单提交功能，集成 Avaloq API 提升底层能力，运用编辑距离算法优化股票代码搜索体验。
- 在数字银行（DBS DigiBank CN）项目开发共同基金、结构性理财产品等微服务。通过 PCF 日志分析生成 QPS 报告协助性能测试。开发 Karate 测试自动化工具提升测试覆盖率。
- 采用 Java/Spring Cloud 技术栈，基于 PCF 云平台和 Kibana 日志系统，实践 BDD/TDD 方法论。

个人执业

中国广州

全栈工程师

2020 年 1 月 - 2021 年 11 月

- 撰写技术博客分享知识，通过 Netflix 和英文原著提升语言能力，解决约 500 道算法题并参加 Codeforces 竞赛。
- 实践 Spark/Hadoop/Kubernetes/Docker 入门教程，积累大数据和云原生技术基础。
- 承接 LED 显示屏官网开发 (lvchensign.com)、ShowMeBug 企业微信集成、无纺布贸易数据爬虫、mathjax2mobi 电子书工具等自由项目。
- 企业微信集成项目使用 Ruby on Rails 实现技术面试工具对接，数据爬虫项目通过 Python/Selenium 自动化采集并生成商业分析报告。
- mathjax2mobi 工具将含 LaTeX 公式的 HTML 转换为 SVG 图片，支持 MOBI 等电子书格式，技术栈含 Python/BeautifulSoup/Selenium。

北京平方根科技有限公司

中国北京

创始人兼全栈工程师

2016 年 7 月 - 2019 年 12 月

- 在 3.5 年内运营了两块业务。2016 年 7 月至 2017 年 9 月，推出并运营了知识直播平台“趣直播”。2018 年 1 月至 2019 年 12 月，转型为软件咨询业务。
- 趣直播：累计举办 80 场讲座，获 3 万用户和千万级浏览量。讲师使用 OBS 推流，用户可实时参与或查看回放。平台与微信深度集成。主力开发了 3 个 Web 客户端和 1 个服务器，代码提交量约 2000 次。技术栈：PHP/Vue/MySQL/Redis/LeanCloud/阿里云/SRS/微信 SDK。
- 软件咨询：完成 50 个定制项目，总营收 300 万元，利润约 70 万元。负责项目洽谈、团队管理及核心开发。主导项目包括：
- 面包 Live 后端重构：将 ThinkPHP/Node.js/Go 技术栈统一迁移至 Laravel，实现课程、支付、分销等模块，与喜马拉雅平台内容同步。
- 江苏卫视《最强大脑》微信小程序：全栈开发益智答题游戏，通过 Redis 应对高并发场景。
- 冲顶大会直播答题 APP：基于 Java/Spring/Kafka 实现实时问答系统，运用 Socket.IO 处理交互，研究 SEI 时间戳同步方案保障直播流与题目同步。

北京大米互娱有限公司

中国北京

联合创始人兼全栈工程师

2015 年 11 月 - 2016 年 7 月

- 大米互娱是由包括我在内的 6 名互联网爱好者共同创立的公司。推出并运营了 CodeReview 平台，这是一个集代码评审、交流和分享于一体的专业平台，积累了约 3000 名用户。
- 该平台功能包括用户管理、代码提交和评审流程、通知系统、支付集成以及活动和研讨会管理。工程师可以提交代码由专家评审以提高质量，专家则获得评审费。同时为用户提供线下研讨会和活动。
- 负责后端系统及半数前端开发，技术栈包括 PHP/Vue/CodeIgniter/阿里云/Ping++ 支付。

美味书签（北京）信息技术有限公司（LeanCloud）

中国北京

软件工程师

2014 年 7 月 - 2015 年 11 月

- 美味书签（LeanCloud）是中国领先的云计算服务商。提供包括对象存储、文件存储、Web 托管、容器、即时通讯、推送、短信和游戏后端在内的全套云服务，服务于数十万开发者用户。
- 参与 LeanCloud Objective-C/Java SDK 开发，主导即时通讯演示应用 LeanChat 的 iOS/Android 客户端开发。
- 技术栈涵盖 iOS/Android SDK、Cocoapods、Xcode、Android Studio 及 Angular 框架。

教育背景

广东外语外贸大学

中国广州

计算机应用专科（自考）

2022.10 至今

- 中国全国高等教育自学考试。该项目需通过 18 门笔试和 5 门实践考试，每年 2-3 次在指定考点由监考老师组织的现场考试。
- 已通过 13 门笔试: 操作系统概论、数据结构导论、高级语言程序设计(一)、英语(一)、高等数学(工专)、数据库及其应用、计算机应用技术、法学概论、计算机组成原理、Java 语言程序设计(一)、移动应用开发技术、网页设计与制作、思想道德与法治。
- 已通过 3 门实践考试: 计算机程序设计基础、计算机基础及应用技术、数据库及其应用。
- 待通过 5 门笔试: 计算机网络技术、交换与路由技术、大学语文、习近平新时代中国特色社会主义思想概论、毛泽东思想和中国特色社会主义理论体系概论。
- 待通过 2 门实践考试: 网页设计与制作、移动应用开发技术。

北京林业大学

中国北京

数字媒体艺术本科（肄业）

2013.09-2014.06

- 修读 13 门课程，含计算机导论、程序设计基础、程序设计基础实验、大学英语、高等数学、数字图像原理与技术、二维图形技术等
- 开发校园助手 Android 应用“北林小助手”，集成查分和校友论坛功能，校内下载量达数千次；另开发通过电影片段学英语的 Android 应用，获黑客马拉松三等奖
- 2014 年蓝桥杯大赛一等奖。在校 ACM/ICPC 月训赛中排名全校第一（约 100 名顶尖学生参赛，包括高年级学生）
- 数字作品《妈妈羞于说的事》获联合国教科文组织与中国传媒大学联合主办的“青春·健康·新媒体”数码作品创意大赛三等奖

广州玉岩中学

中国广州

理科中学文凭

2007 年 7 月-2013 年 6 月

- 广州中考成绩 756 分（满分 810 分），位列全市前 300 名（考生约 10 万人）
- 2011 年广东 NOIP（全国青少年信息学奥林匹克联赛）普及组广州一等奖；进入省赛未获奖；可能排名前 300

企业项目经历

全栈开发、后端开发、平台集成、团队管理

多元化企业项目

2014 - 2024

- 汇丰金融转型平台（2025.02 - 至今）作为 AI 工程师参与开发，使用 Java、Spring、Python、IBM WebSphere 和 Copilot 等技术栈
- AI 故事机器人：基于 Claude API 开发个性化故事生成系统。技术栈：Python、Flask、React、AWS（2024.05 - 2024.07）
- 汇丰 PayMe：自动充值功能开发及云迁移。技术栈：Java、Spring Cloud、Azure、AWS（2022.11 - 2023.07）
- 星展银行 Digibank 中国版：基金微服务后端开发。技术栈：Java、Spring Cloud、Pivotal Cloud Foundry（2022.07 - 2022.11）
- 星展银行 Client Connect：股票交易微服务后端开发。技术栈：Java、Spring Cloud、Pivotal Cloud Foundry（2021.12 - 2022.06）
- ShowMeBug：企业微信平台集成，含登录及面试入口功能。技术栈：Ruby on Rails、PostgreSQL、微信 SDK（2021.07 - 2021.09）
- Square Root Inc 项目：主导 50+ 网站/游戏/应用/小程序开发，负责团队管理、合同谈判、项目管理、客户沟通及软件开发（2018.01 - 2019.12）
- 《最强大脑》微信小程序：电视节目配套小程序前后端开发。技术栈：Java、Spring、JavaScript、HTML、阿里云（2018.02 - 2018.03）
- 冲顶大会：直播答题应用前后端开发。技术栈：Java、Spring、WebSocket、Netty（2017.09 - 2018.01）
- 面包 Live：内容变现平台后端重构。技术栈：PHP、TypeScript、Laravel、Go（2017.09 - 2018.01）
- 趣直播：知识直播平台全栈开发。技术栈：PHP、JavaScript、HTML、阿里云、RTMP 流媒体（2016.06 - 2017.09）
- LeanCloud SDK 及 LeanChat：Objective-C 与 Java SDK 及其演示应用开发（2014.07 - 2015.10）

个人项目

- 使用 nanoGPT 在 FineWeb 数据集上从零训练 GPT-2 124M 两次——分别在 RunPod H200 (141 GB HBM3e) 和 DigitalOcean H100 (80 GB HBM3) 上完成；另在配备 RTX 4070 (12 GB) 的家用服务器上进行了实验。Fork 了 Karpathy 的 nanoGPT 并提交 45 次：基于 FineWeb 分片的数据流水线、内联张量形状注释和适配不同 GPU 预算的训练配置。技术栈：Python、PyTorch、CUDA、HuggingFace Datasets、tiktoken。
- 构建了包含 6 个数据集流水线 (FineWeb-Edu 10B+ tokens、OpenWebText、Wikipedia) 和 6 个训练配置 (124M–1.5B 参数) 的 nanoGPT 分支。另在 AMD MI300X (192 GB HBM3) 上通过 AMD Dev Cloud 训练 GPT-2 760M。技术栈：Python、PyTorch、ROCm、FlashAttention、HuggingFace Hub。
- MoE 与 LLM 推理：从训练扩展到 MoE 与服务系统，通过阅读代码、运行和从源码编译来学习。端到端研究 MoE 架构 (DeepSeek-MoE、MegaBlocks、Tutel、Mixtral) ——路由、调度、专家计算、组合与负载均衡。在 RTX 4070 上运行 nano-vLLM 提供 Qwen3-0.6B 服务，使用 flash-attention (预填充 506 tok/s, 基准约 1434 tok/s)，并学习服务栈：分页 KV 缓存、分块预填充/解码调度、连续批处理、CUDA 图谱和张量并行。从源码编译 SGLang (构建其 3 个 PyO3 Rust 扩展) 并提供 Qwen2.5-0.5B 的 OpenAI 兼容 API 服务。技术栈：Python、PyTorch、CUDA、Triton、FlashAttention、nano-vLLM、SGLang、vLLM、ROCm、NCCL。
- SEC-EDGAR-GPT：在 SEC EDGAR 财务文件 (10-K、10-Q、8-K) 的 15.5 亿 token 上，使用 nanoGPT 在单个 RTX 4070 (12 GB) 上从零训练 GPT-2 124M。约 8 小时收敛到验证损失 2.28。构建了论文、项目网站 (Cloudflare Workers)、聊天界面 (nanoGPT 服务器) 和 HuggingFace 模型仓库。整个项目通过 Hermes Agent 在 3 天内完成。技术栈：Python、PyTorch、nanoGPT、HuggingFace Hub、Cloudflare Workers、tiktoken。
- zz：数据集处理工具集——支持断点续传的分片下载及 token 预算规划、通过 pyarrow 进行内存安全的 parquet 提取、tokenization、训练日志分析。托管于 GitHub 和 Hugging Face。技术栈：Python、pyarrow、tiktoken、pandas、matplotlib。
- 在多个平台消耗约 23 亿 + token：OpenRouter 11.5 亿 token (\$239, 155K 请求)、Claude API 1.15 亿 + token、小米 MIMO 5 亿 token。技术栈：OpenRouter API、Claude API、Copilot API、REST APIs。
- jekyll-ai-blog：AI 驱动的博客平台，支持基于 LLM 的多语言翻译 (9+ 语种)、Google Cloud TTS 音频生成、XeLaTeX PDF/EPUB 流水线及 GitHub Actions CI/CD。10K+ 英文文章、10K+ 中文文章、9.7K AI 笔记。技术栈：Jekyll、Python、Google Cloud TTS、XeLaTeX、DeepSeek、Mistral。
- lzwjava.com：个人博客与知识库，约 400 篇原创文章及约 8000 条 AI 回答笔记；每月约 7 万页面浏览量 (Cloudflare)。技术栈：Jekyll、GitHub Pages、Cloudflare Analytics、MathJax。
- ww：跨平台 CLI 工具集 (255+ 次提交, 10+ 命令组) ——集成 AI 提交信息的 git workflows、笔记管理、图片/PDF 处理、Copilot Chat、AMD Dev Cloud 管理。技术栈：Python、uv、Gemini Flash、OpenRouter、Pillow。
- FluxReel：AMD AI DevMaster Hackathon 2026-07 (赛道 1) ——将一行主题转化为 15 秒竖版短视频 (1080×1920, 30 fps)，图片生成运行在 AMD Radeon GPU (ROCm) 上。流水线：LLM 脚本 +5 个双语场景、并行图片生成 (diffusers FLUX.1-schnell / stable-diffusion.cpp GGUF / OpenRouter 备用)、PIL 幻灯片合成 (含 CJK 字幕)、ffmpeg 组装。包含 FastAPI Web UI+REST API、可选 YouTube 上传和远程 AMD GPU 管理。技术栈：Python、diffusers、FLUX.1-schnell、stable-diffusion.cpp、ffmpeg、PIL、FastAPI、ROCm、OpenRouter。
- iclaw：终端 AI 智能体 REPL，支持原生工具调用——可自主编码、搜索并执行命令。支持 Copilot OAuth 和 OpenRouter；适用于受限企业环境。技术栈：Python、Copilot OAuth、OpenRouter API、DuckDuckGo、Tavily。
- live-server 现代化改造：通过 AI 编程工具 (Claude Code、Codex) 完成 Docker 化，升级 CodeIgniter 和 Vue 至当前版本，实现曾服务 3 万用户的创业项目全栈现代化。技术栈：PHP、Docker、CodeIgniter、Vue.js、MySQL、Redis。
- Tree_Of_Thought (1 个 PR)：为思维树推理系统贡献代码，用于物理问题求解——含显式推理树、评分、剪枝和 SymPy 符号计算。新增 OpenAI 兼容请求模块及 python-dotenv 配置支持。技术栈：Python、FastAPI、OpenAI API、SymPy。

开源贡献、博客开发、后端与前端开发、移动应用开发、工具开发

各类个人项目

2013 年至今

- 算法解决方案：算法问题的解决方案，托管在 GitHub 上，有 2466 次提交，主要使用 Java 实现。(2013 年至今)
- 个人博客：维护一个双语博客（英文和中文），有 500 次提交，分享编程、技术和个人发展的见解。(2013 年至今)
- 直播服务器：使用 PHP 开发的知识直播平台后端，有 660 次提交。(2016 - 2017 年)
- 直播移动网页：使用 Vue 和 JavaScript 开发的知识直播平台移动前端，有 528 次提交。(2016 - 2017 年)
- 直播网页：使用 Vue 开发的知识直播平台桌面前端，有 140 次提交。(2016 - 2017 年)
- 直播微信小程序：使用 JavaScript 开发的知识直播平台微信小程序，有 63 次提交。(2016 - 2017 年)
- 代码审查服务器：使用 PHP 开发的专业代码审查平台后端，有 275 次提交。(2015 - 2016 年)
- 代码审查网页：使用 Vue 和 JavaScript 开发的专业代码审查平台前端，有 302 次提交。(2015 - 2016 年)
- LeanChat iOS：展示 LeanCloud SDK 的 iOS 聊天应用，使用 Objective-C 实现，有 556 次提交。(2014 - 2015 年)
- LeanChat Android：展示 LeanCloud SDK 的 Android 聊天应用，使用 Java 实现，有 412 次提交。(2014 - 2015 年)
- 费曼讲座 Mobi：开发将 LaTeX 转换为 SVG 以创建 mobi 电子书的工具，使用 Python 实现，有 47 次提交。(2020 - 2021 年)

博客文章

以下是我精选的一些博客文章，涵盖了个人成长故事、创业历程、英语学习、编程、极客项目等内容。

精选博客文章

- LLM 成本、智能体与编码工具
- 为 AI 优化软件工程
- 在 Azure 上构建可扩展的应用程序
- Spring 框架全面指南
- 使用 Flask、React 和 ELK 构建 AI 驱动的故事机器人
- 使用 Pivotal Cloud Foundry 进行部署
- 学习的智慧
- 禅与机器学习艺术
- 如何组装一台电脑
- 给工程师推荐的博客文章
- 元思维框架
- 完整人生哲学
- 在低于完整处方 1.50D 的日常眼镜使用体验
- 完整英语学习指南
- 使用 OBS、SRS 和 FFmpeg 设置直播
- 猎云网：95 后创业者创立知识直播平台去直播
- 通过自动化测试和工具提升 iOS 开发
- 我的美国之行：硅谷初印象
- 将 FFmpeg 移植到 Android
- Android 自定义绘制深入解析

论文

我是一名自学成才的研究者，受到 Yin Wang 和 Todd Becker 工作的启发，经过三年的实验，撰写了一篇关于逆转近视和自然视力恢复的学术风格论文，并发表了一篇关于从零训练 GPT-2 处理 SEC 文件的 AI 研究论文。

在计算机科学领域，我仍在努力取得类似的突破。

自然视力恢复：实验验证、散光减少与”刚好清晰”原则

李智维的博客

李智维

2026 年 8 月

- 将三篇论文合并为一项统一研究：验证了自然视力恢复方法，分析了逆转近视过程中的散光减少，并引入了”刚好清晰”原则。
- 在线发布: <https://lzwjava.com/natural-vision-restoration-en>

SEC-EDGAR-GPT: 基于 SEC EDGAR 文件从零训练的 GPT-2 (124M) 语言模型

GitHub

李智维

2026 年 6 月

- 使用 nanoGPT 在单个 RTX 4070 上从零训练 1.24 亿参数的 GPT-2，基于 SEC EDGAR 财务文件 (10-K、10-Q、8-K) 的 15.5 亿 token。约 8 小时收敛到验证损失 2.28。
- 在线发布: [sec-edgar-gpt.pdf](#)
- 代码: github.com/lzwjava/sec-edgar-gpt | 模型: huggingface.co/lzwjava/sec-edgar-gpt-124m-hf

技能

- 2008 年开始编程。以下按累计使用时间展示相对熟练度，与工作经历不同。
- 5 年以上经验：中文、英语、写作、Java、算法、测试驱动开发、云计算、DevOps、后端开发、AI 辅助开发
- 3-4 年经验：粤语、iOS 开发、Android 开发、机器学习、LLM API、AI 智能体开发
- 1-2 年经验：产品管理、前端开发、GPU 训练与推理 (PyTorch、CUDA、ROCm)、提示工程、模型微调
- 1 年以下经验：日语

工具集

以下是我积累上述技能所使用的详细工具列表，以及其他有趣的工具。其中部分工具我仍在持续使用，其余工具只需稍加复习即可重新掌握。

- 自然语言：英语、汉语、粤语、客家话、日语
- 操作系统：Linux、Windows、MacOS、Android、iOS、OpenWRT
- 编程语言：PHP、Java、Objective-C、Swift、Ruby、HTML、C、C++、JavaScript、Lisp、Clojure、TypeScript、Node.js、Go、Python、Pascal
- Java：JDK 8/17、Spring MVC/Core、SLF4J、Jackson、Hibernate、JaCoCo、FeignClient、XML、Reflections、Servlet、Executor
- Python：3.8/3.11、Flask、logging、json、SQLAlchemy、unittest、requests、xml.etree、inspect、http.server、concurrent.futures
- 领域特定语言：JSON、CSS、SQL、NoSQL、Kusto 查询语言、Kibana 查询语言
- 数据库：MySQL、SQLite、PostgreSQL、Microsoft SQL Server、Amazon RDS、MongoDB、IBM Db2、Navicat
- 数据库客户端：Squirrel SQL Client、DBeaver、MySQL Workbench、Sequel Pro、Navicat、Eclipse 数据源浏览器
- 前端技术：Vue、React、Angular、jQuery、Hexo、Jekyll、Stylus、Sass、Chrome、Safari
- 开发框架：RTMP 流媒体、HTTP/IP 协议栈、Spring、Spring Boot、Hibernate、Netty、CodeIgniter、Laravel、Flask、Express、Socket.IO、iOS SDK、Android SDK、Flutter
- 大数据：Redis、Kafka、Spark、Flink、ZooKeeper
- 数学工具：微积分、线性代数、离散数学、Latex 排版
- IDE：Emacs、IntelliJ IDEA、Visual Studio Code、Xcode、Android Studio、Eclipse、PyCharm、PhpStorm、Sublime Text、Atom、WebStorm、Delphi、Turbo Pascal
- 终端：Powershell、Command Prompt、iTerm2、GNOME Terminal、Terminal (macOS)
- 开发工具：NPM、Webpack、Git、HomeBrew、Gradle、Maven、Sketch、Cocopods、WordPress、YourKit Java 分析器
- 持续集成：Travis CI、GitHub Actions、Jenkins、Azure DevOps、Control-M
- 监控系统：SonarQube、Prometheus、Elasticsearch、Logstash、Kibana、Nginx、Docker、Kubernetes
- 机器学习：TensorFlow、PyTorch、Theano、Anaconda、Jupyter Notebook、CUDA、Numpy、Pandas
- 云服务：GitHub、GitLab、Digital Ocean、Vultr、AWS、Azure、Google 云平台、Linode、阿里云、七牛云、腾讯云、LeanCloud、Firebase、Cloudflare、GoDaddy、声网、Vercel
- 应用运行时：IBM WebSphere Liberty 服务器、IBM WebSphere Application Server、Pivotal Cloud Foundry、PM2
- 项目管理：Jira、Confluence、ServiceNow、Trello、Microsoft 待办事项、Tower.im
- 大语言模型：OpenAI、Claude、MiniMax、Amazon Bedrock、Copilot、LangChain、vLLM、Llama.cpp、OpenRouter、Claude Code、Codex、Copilot API、Claude Code Router
- Linux 工具：nmap、grep、awk、ffmpeg、htop、df、lsblk、strace、tcpdump、iostat、iptables、rsync、journalctl、systemctl、curl、tmux、traceroute、emacs、diff
- 测试工具：Postman、Selenium、Karate、JUnit、Spring Boot Starter Test、Mockito、Apache JMeter、Apache ab、Playwright、Python unittest
- 硬件开发：Arduino UNO、Raspberry Pi Pico

知识领域

以下是我专业知识和知识领域的总结。虽然我对某些主题有扎实的理解，对其他主题有基本的了解，但如果您对任何特定领域感兴趣，我将在面试中乐意分享更多信息。

行业知识

- 银行与支付、教育与电子学习平台、社交媒体与内容平台、用户与账户管理、通知系统、数据与分析、移动应用程序、支付系统、交易管理、社交媒体集成、视频管理、奖励系统、实时视图跟踪、应用程序管理、共同基金与股票交易、基于浏览器的编程环境。

- 高等数学、计算机组成、操作系统、计算机网络技术、数据库与应用、计算机应用技术、数据结构与算法、微机与接口技术。

技术与开发

- 多语言沟通、跨平台开发、全栈编程、数据库管理、机器学习与大数据、数学能力、开发工具、机器学习实现、高级 Linux 使用、测试与质量保证、API 集成、开源贡献、技术写作与博客、云计算服务、分布式系统、高性能优化、实时应用、RTMP 流媒体。
- 持续集成/持续部署 (CI/CD)、容器化与编排、网络安全、敏捷方法、软件架构、DevOps 实践、云原生应用、API 开发、版本控制系统、无服务器计算、性能监控、数据工程、安全最佳实践、软件开发生命周期 (SDLC)、技术指导、项目管理。

创业精神与产品思维

- 曾创立两家创业公司：一家与合伙人共同创立，另一家由我独立创建。后者获得了 3 万用户，年营收曾达到 300 万人民币。
- 22 岁时为自己的创业项目赢得约 50 万人民币投资，并在关闭公司时将剩余资金退还给投资者。
- 曾两次申请 Y Combinator。其中一次进入第二轮面试（录取率约为 3%），虽然最终未入选该批次。
- 乐于在大公司提出新想法以切实帮助项目；尝试过多种方式并在本地开发分支中创建了原型证明 (PoC)。向技术主管展示这些想法以推动进展，部分想法获得了良好反馈。
- 拥有丰富的社交媒体影响力实践经验，包括博客、微信公众号、TikTok、微信视频号、微博和 LinkedIn。每年获得数千名关注者或 6 万次页面浏览。
- 使用 3 部手机和上千个应用程序及游戏进行体验，包括来自数十个国家的不同类型的應用。
- 作为 Blue Sky 的早期用户，我在 Jeff Dean（Google 首席科学家）的首条帖子下留言并获得了他的点赞。
- 拥有数百种小工具和设备，如电磁场测量仪等。
- 如果产品价格低廉，非常愿意购买不同种类的产品进行对比并理解其细微差别。
- 阅读了约 100 本关于商业、管理和产品的书籍。与这些领域的专家保持着一定的联系。
- 自 2018 年起成为加密货币和美股投资者，曾因亏损休息过一段时间，但在 2024 年恢复投资，采用长期定期定额投资策略。尽管金额不大，但很高兴在经过一年的定投后，截至 2025 年 7 月，NVIDIA 的投资获得了 25% 的利润，部分比特币投资获得了 30% 的利润。

证书

- 2014 北京林业大学退学证明, 北京林业大学
- 2014 中国高等教育学历认证报告（本科教育，退学状态）, 中国高等教育学生信息网
- 广东省高等教育自学考试成绩单（已通过 13 门科目）, 广东省高等教育自学考试委员会
- 2025 雅思学术类考试，成绩 6.5 分, 英国文化协会
- 2023 机器学习专项课程结业证书, DeepLearning.AI 与斯坦福大学
- 2023 深度学习专项课程结业证书, DeepLearning.AI
- 2023 Developing on AWS, AWS 培训

链接

- **GitHub:** <https://github.com/lzwjava>
- **博客:** <https://lzwjava.com>
- **Codeforces:** <https://codeforces.com/profile/lzwjava>
- **UVa Online Judge:** <https://uhunt.onlinejudge.org/id/113519>
- **Kaggle:** <https://www.kaggle.com/lzwjava>
- **LinkedIn:** <https://www.linkedin.com/in/lzwjava>